# Computação Distribuída

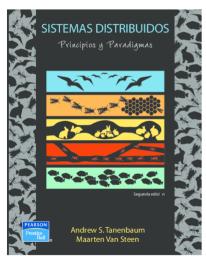
Comunicação

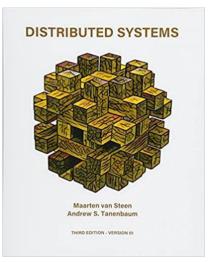
Chapter 4

#### COMMUNICATION

Vladimir Rocha (Vladi)

CMCC - Universidade Federal do ABC





2007 2017

#### Disclaimer

- Estes slides foram baseados nos do professor Emilio Francesquini para o curso de Sistemas Distribuídos na UFABC.
- Este material pode ser usado livremente desde que sejam mantidos, além deste aviso, os créditos aos autores e instituições.
- Estes slides foram adaptados daqueles originalmente preparados (e gentilmente cedidos) pelo professor Daniel Cordeiro, da EACH-USP que por sua vez foram baseados naqueles disponibilizados online pelos autores do livro "Distributed Systems", 3ª Edição em: https://www.distributed-systems.net.

### Agenda

- Fundamentos
- Comunicação orientada a procedimento (RPC)
- Comunicação orientada a mensagem (MOM)
- Comunicação multicast (FIFO/Causal/Total Gossip/Flooding)
- Comunicação orientada a fluxo

### Agenda

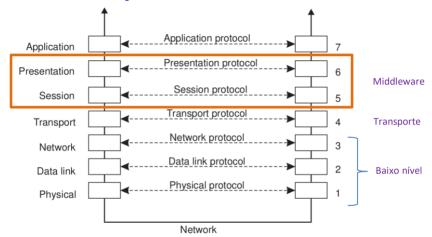
#### Fundamentos

- Comunicação orientada a procedimento (RPC)
- Comunicação orientada a mensagem (MOM)
- Comunicação multicast (Gossip / Flooding)
- Comunicação orientada a fluxo

#### Protocolos em camadas

- Camadas de baixo nível
- Camada de transporte
- Camada do middleware
- Camada de aplicação
- Tipos de comunicação

# Modelo de comunicação básico



#### Desvantagens:

- Funciona apenas com passagem de mensagens
- Frequentemente possuem funcionalidades desnecessárias
- Viola a transparência de acesso



### Camada de transporte

#### Importante:

A camada de transporte fornece as ferramentas de comunicação efetivamente utilizadas pela maioria dos sistemas distribuídos.

#### Protocolos padrões da Internet

TCP: orientada a conexão, confiável, comunicação orientada a

fluxo de dados

UDP: comunicação de datagramas não confiável(best-effort)

#### Nota:

IP multicasting é normalmente considerado um serviço padrão (mas essa é uma hipótese perigosa)

#### Camada de middleware

Middleware foi inventado para prover serviços e protocolos frequentemente usados que podem ser utilizados por várias aplicações diferentes.

- Um conjunto rico de protocolos de comunicação
- (Des)empacotamento [(un)marshaling] de dados, necessários para a integração de sistemas
- Protocolos de gerenciamento de nomes, para auxiliar o compartilhamento de recursos
- Protocolos de segurança para comunicações seguras
- Mecanismos de escalabilidade, como replicação, sharding e caching

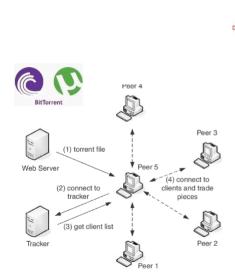
#### Observação:

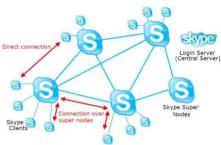
O que realmente sobra são protocolos específicos de aplicação.



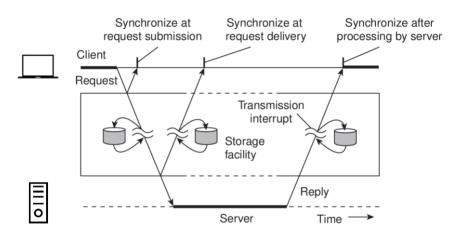
#### Camada de aplicação

www.img.lx.it.pt%2F~fp%2Fcomunicacao\_multimedia%2Fano%2520lectivo\_2011 \_2017%2FTrabalhos\_CMul\_2016\_2017%2FGrupo%25203%2Farquitetura.html



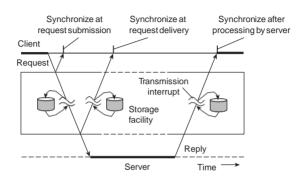


### Tipos de comunicação



- Comunicação transiente vs. persistente
- Comunicação assíncrona vs. síncrona

### Tipos de comunicação

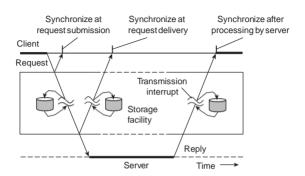


#### Transiente vs. persistente

Comunicação transiente: remetente descarta a mensagem se ela não puder ser encaminhada para o destinatário

Comunicação persistente: uma mensagem é guardada no remetente pelo tempo que for necessário, até ser entregue no destinatário

### Tipos de comunicação



#### Pontos de sincronização

- No envio da requisição
- Na entrega da requisição
- Após o processamento da requisição

### Agenda

- Fundamentos
- Comunicação orientada a procedimento (RPC)
- Comunicação orientada a mensagem (MOM)
- Comunicação multicast (Gossip / Flooding
- Comunicação orientada a fluxo



# Chamadas a procedimentos remotos (RPC)

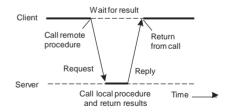
- Funcionamento básico de RPCs [Nelson 1984]
- Passagem de parâmetros
- Tipos de comunicação
- Exemplo

#### RPC: Funcionamento básico

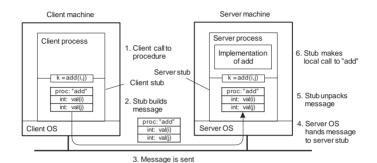
- Desenvolvedores estão familiarizados com o modelo de procedimentos
- Procedimentos bem projetados operam isoladamente (black box)
- Então não há razão para não executar esses procedimentos em máquinas separadas

#### Conclusão

Comunicação entre o chamador & chamado podem ser escondida com o uso de mecanismos de chamada a procedimentos.



#### RPC: Funcionamento básico



across the network

- Procedimento no cliente chama o stub do cliente
- Stub constrói mensagem; chama o SO local
- 3. SO envia msg. para o SO remoto
- SO remoto repassa mensagem para o stub
- Stub desempacota parâmetros e chama o servidor

- Servidor realiza chamada local e devolve resultado para o stub
- 7. Stub constrói mensagem; chama SO (volta)
- SO envia mensagem para o SO do cliente
- SO do cliente repassa msg. para o stub
- Stub do cliente desempacota resultado e devolve para o cliente



#### RPC: concorrência

Que acontece quando vários clientes acessam o método?

Depende da implementação. Normalmente (e.g., Java RMI) utiliza-se o modelo dispatcher/worker.

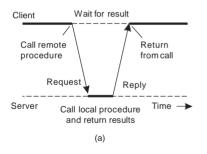
Ou seja, cada requisição do cliente é atendida por uma thread diferente.

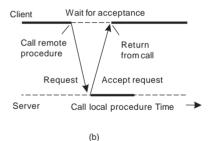
Isso quer dizer que é necessário proteger as variáveis e estruturas de acessos concorrentes.

### RPC: tipos de comunicação →assíncrono

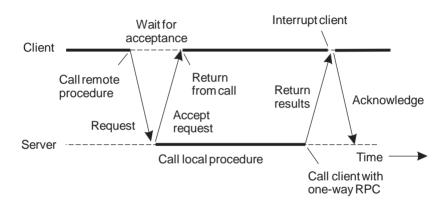
#### Ideia geral

Tentar se livrar do comportamento estrito de requisição—resposta, mas permitir que o cliente continue sem esperar por uma resposta do servidor.





# RPC: tipos de comunicação → síncrono diferido

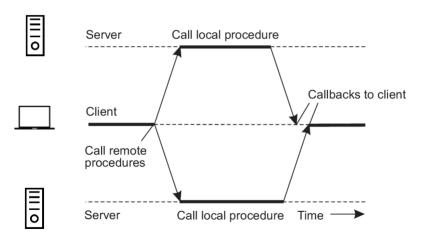


#### Variação

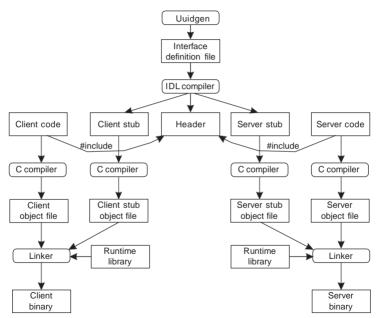
Cliente pode também realizar uma consulta (poll) (bloqueante ou não) para verificar se os resultados estão prontos.

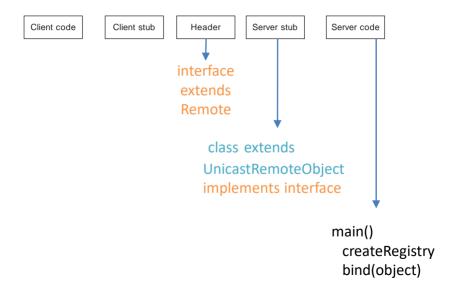
# RPC: tipos de comunicação → Enviando várias

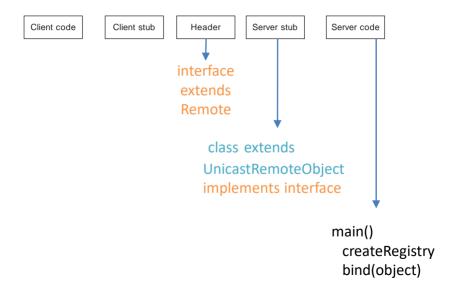
#### Enviando um pedido de RPC a um grupo de servidores



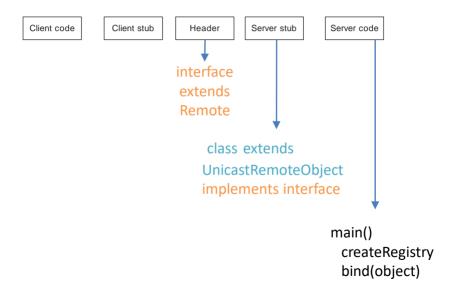
### RPC: Exemplo



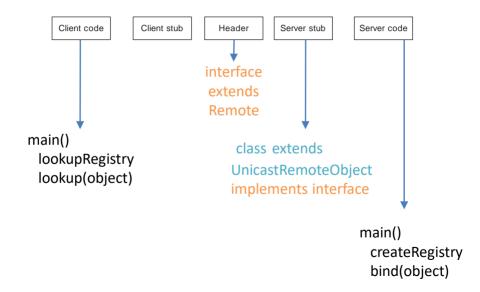




```
import etml.*
public class ServicoImpl
              extends UnicastRemoteObject
              implements ServicoMatriz {
   public int[][] inverte(int[][] matrizGigante)
                          throws RemoteException {
        Matrix m = new Matrix(matrizGigante);
        return m.invert();
```



# RPC: Exemplo (RMI – Remote Method Invocation) public class Servidor { public static void main(String[] args) { ServicoMatriz sm = new ServicoImpl(); LocateRegistry.createRegistry(1099): Registry reg = LocateRegistry.getRegistry(); reg.bind("rmi://127.0.0.1/servicomat", sm);



```
public class Cliente {
   public static void main(String[] args) {
      Registry reg = LocateRegistry.getRegistry();
      ServicoMatriz sm = (ServicoMatriz)
      reg.lookup("rmi://127.0.0.1/servicomat");
      int [][] mat = {};
      int[][] inv = sm.inverte(mat);
```

### RPC: Exemplo (gRPC – Google RPC)

#### Google Remote Procedure Call

Desenvolvido pela Google em 2015.

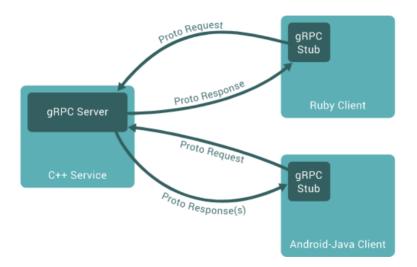
- Mensagens 3 a 10 dez vezes menores
- Enviadas 20 a 100 vezes mais rápido

#### Cenários comuns de uso:

- Quando precisar de baixa latência e alta escalabilidade.
- Clientes móveis comunicando-se com a nuvem
- Permitir facil extensão para outros componentes (auth, balanceamento, etc).

Usado por empresas tais como: Uber, Netflix, IBM, Dropbox, Cisco ...

### RPC: Exemplo (gRPC - Google RPC)

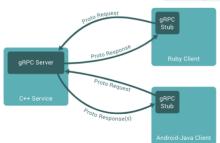


### RPC: Exemplo (gRPC – Google RPC)

```
// The greeter service definition.
service Greeter {
    // Sends a greeting
    rpc SayHello (HelloRequest) returns (HelloReply) {}
}

// The request message containing the user's name.
message HelloRequest { string name = 1; }

// The response message containing the greetings
message HelloReply { string message = 1; }
```



# Agenda

- Fundamentos
- Comunicação orientada a procedimento (RPC)
- Comunicação orientada a mensagem (MOM) \*
- Comunicação multicast (Gossip / Flooding
- Comunicação orientada a fluxo









\* Usados como: event-streaming platform

# Comunicação orientada a mensagens

- Middleware orientado a mensagens (filas)
- Message broker
- Exemplo: Apache Kafka

# Middleware orientado a mensagens

#### Ideia geral

Comunicação assíncrona e persistente graças ao uso de filas gerenciadas pelo middleware. Filas correspondem a buffers em servidores de comunicação.

PUT	Adiciona uma mensagem à fila especificada
GET	Bloqueia até que a fila especificada tenha alguma mensagem
	e remove a primeira mensagem
POLL	Verifica se a fila especificada tem alguma mensagem. Nunca bloqueia
NOTIFY	Instala um tratador para ser chamado sempre que uma mensagem for inserida em uma dada fila

# Message broker

## Observação:

Sistemas de filas de mensagens assumem um protocolo comum de troca de mensagens: todas as aplicações usam o mesmo formato de mensagem (i.e., estrutura e representação de dados)

### Message broker

Componente centralizado que lida com a heterogeneidade das aplicações:

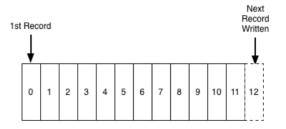
- transforma as mensagens recebidas para o formato apropriado
- frequentemente funciona como um gerenciador e/ou armazenador da fila

# Message broker

- Mensagens específicas da aplicação são colocadas e removidas de filas
- As filas são controladas por um gerenciador de filas (e.g., um broker)
- Processos podem inserir mensagens em filas locais ou remotas, usando um mecanismo de RPC



- Exemplo de MOM, desenvolvido pelo LinkedIn [2012]
- Uma das plataformas de mensagerias open source mais usadas
- Utiliza o conceito de event log (i.e., estrutura append-only) onde cada registro possui um identificador único que captura a ordem dos eventos.



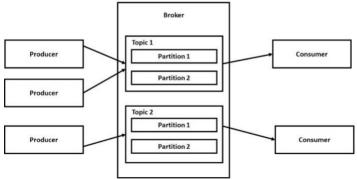
https://engineering.linkedin.com/distributed-systems/log-what-every-software-engineer-should-know-about-real-time-datas-unifying and the state of the state of



- Os logs (i.e., filas) s\u00e3o administrados/persistidos pelo Kafka broker
   O kafka broker \u00e9 stateless para requisi\u00f3\u00f3es de clientes
- O produtor envia os eventos ao broker de forma assíncrona
- Os eventos s\(\tilde{a}\)o armazenados de forma persistente no log.
- Podem ser lidos por vários consumidores.

Cada consumidor especifica o log e o índice (offset).

No Kafka, o log é denominado de *Topic* 

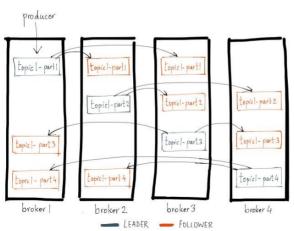


- Para a escalabilidade, kafka usa o particionamento (sharding) do tópico
  - Na criação você define a quantidade de partições
  - Permite a escalabilidade horizontal
  - Permite que produtores e consumidores paralelizem as reqs.
- Como o broker é stateless, cabe ao produtor escolher a partição onde será registrado o evento.

E.g., Mensagens-SD-DA1, Mensagens-SD-DA2, ...

 Normalmente usa-se o hash de alguma chave (como id) que direciona à partição.

- Para a disponibilidade, kafka usa a replicação do tópico
  - Um líder, responsável por atender leituras e escritas.
  - N seguidores, responsáveis por resiliência a falhas do líder. (não aceitam leituras e/ou escritas)





- Slack (discord-like) usa kafka
  - Captura eventos de clientes Web que demandarão muito tempo para serem processados.
  - Em 2018, processou mais de 1 bilhão de mensagens por dia usando 16 brokers na AWS

Instância i3.2xlarge: 8 vCPU, 61 GB RAM. Partições por tópico 32. Fator de replicação 3.

# Apache ActiveMQ



O ActiveMQ é um dos mais populares provedores open source (licence Apache 2.0), utilizado para integrar diferentes linguagens, tais como: Java, .NET, C/C++/C#, Delphi, Perl, Python, entre outras, através do chamado "Cross Language Clients".

Desde 2004 até hoje

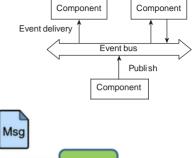
http://activemq.apache.org/

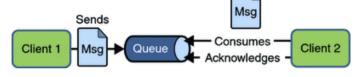
# Apache ActiveMQ: modelos

- · Modelo ponto a ponto
- Modelo publish/subscribe

# Apache ActiveMQ: modelos

Modelo ponto a ponto (queue)

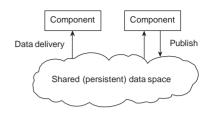


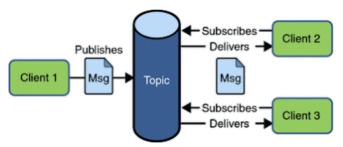


- 1. O produtor envia uma mensagem para a queue
- Somente um dos consumidores (que estão escutando) recebe a mensagem

# Apache ActiveMQ: modelos

Espaço de dados compartilhados





- 1. O produtor envia uma mensagem para o servidor de tópicos
- 2. Todos os consumidores (que estão escutando) recebem a msg

# Vantagens e Desvantagens

Dentro da Aplicação

Fácil de usar – Java ExecutorService Normalmente armazenamento em memória (perda de mensagens/tarefas se cair a app)



Fora da Aplicação (separada)

Armazenamento em disco – Kafka Escalabilidade limitada à máquina.

Fora da Aplicação (distribuída)

Armazenamento em disco, escalabilidade muito grande – Kafka/RabbitMQ/ApacheMQ Complexo de administrar, inconsistências









# Agenda

- Fundamentos
- Comunicação orientada a procedimento (RPC)
- Comunicação orientada a mensagem (MOM)
- Comunicação multicast
   FIFO/Causal/Total e sem ordem.
   Gossip/Flooding
- Comunicação orientada a fluxo

### Multicast

- Diferente do unicast (e.g., TCP) no multicast o emissor sender envia a mesma mensagem para um grupo de destinos - receivers.
- O multicast pode ser realizado pela camada de rede (difícil de ser implementado) ou pelo middleware.
- Pelo middleware, caberá a este verificar que as mensagens sejam entregues aos destinos

# Agenda

- Fundamentos
- Comunicação orientada a procedimento (RPC)
- Comunicação orientada a mensagem (MOM)
- Comunicação multicast
   FIFO/Causal/Total e sem ordem
   Gassin/Flooding
- Comunicação orientada a fluxo

### Multicast ordem FIFO

Se um processo p envia mensagens m1 e depois m2, todos os processos entregarão primeiro m1 antes de m2.

#### No middleware

Receber: não há controle sobre o que se recebe pela camada de rede. Entregar: após receber a mensagem, você controla o que fazer com ela (e.g., entregar para o banco de dados fazer o update)

Entregar ou repassar, ambos termos são usados

## Multicast ordem FIFO

Se um processo p envia mensagens m1 e depois m2, todos os processos entregarão primeiro m1 antes de m2.

tempo	P1	P2
1	Envia/Entrega m1	Entrega m1
2	Envia/Entrega m2	Entrega m2

tempo	P1	P2	Р3
1	Envia/Entrega m1	Entrega m1	Entrega m2
2	Envia/Entrega m2	Entrega m2	Entrega m1

tempo	P1	P2	Р3	P4
1	Envia/Entrega m1	Entrega m1	Entrega m3	Envia/Entrega m3
2	Envia/Entrega m2	Entrega m3	Entrega m1	Envia/Entrega m4
3	Entrega m3	Entrega m2	Entrega m2	Entrega m1
4	Entrega m4	Entrega m4	Entrega m4	Entrega m2

### Multicast ordem CAUSAL

Se uma mensagem *m1* precede causalmente *m2*, todos os processos entregarão primeiro *m1* antes de *m2*.

No capítulo 6 será definido formalmente o termo causalidade. Note que não depende do processo origem que enviou o multicast.

## Multicast ordem CAUSAL

Se uma mensagem *m1* precede causalmente *m2*, todos os processos entregarão primeiro *m1* antes de *m2*.

tempo	P1	P2	P3
1	Envia m1		
2		Entrega m1	
3	Entrega m1	Envia m2	Entrega m1
4	Entrega m2		
5		Entrega m2	Entrega m2

tempo	P1	P2	Р3
1	Envia m1		
2		Entrega m1	
3	Entrega m1	Envia m2	Entrega m2
4	Entrega m2		
5		Entrega m2	Entrega m1

Se um processo entrega *m1* antes de *m2*, todos os processos entregarão nessa mesma ordem.

tempo	P1	P2	P3	P4
1	Envia m1			Envia m2
2		Entrega m2	Entrega m2	
3	Entrega m2	Entrega m1	Entrega m1	Entrega m2
4	Entrega m1			Entrega m1

tempo	P1	P2	Р3	P4
1	Envia m1			Envia m2
2		Entrega m2	Entrega m2	
3	Entrega m1	Entrega m1	Entrega m1	Entrega m2
4	Entrega m2			Entrega m1

# Agenda

- Fundamentos
- Comunicação orientada a procedimento (RPC)
- Comunicação orientada a mensagem (MOM)
- Comunicação multicast

FIFO/Causal/Total

Gossip/Flooding

Comunicação orientada a fluxo

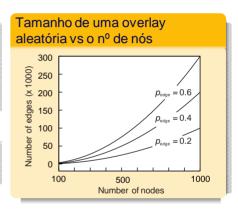
# Disseminação de dados via Gossip / Flooding

#### Ideia

Nó *P* envia uma mensagem *m* a seus vizinhos (via **gossip**). Cada vizinho a re-envia (via **flooding**) se não a viu antes.

#### Desempenho

Maior a quantidade de conexões, mais caro fica



# Gossip: Protocolos Epidêmicos

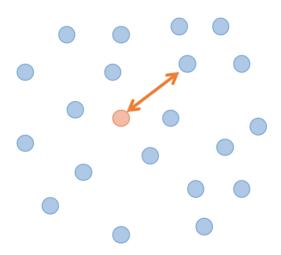
#### Assuma não há conflito escrita-escrita

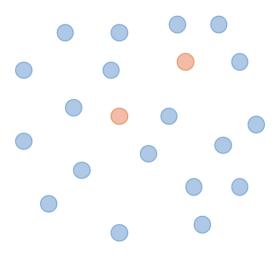
- Operações de atualização são realizadas em um só servidor
- Um nó passa informações (estado) a somente alguns nós
- Propagação de atualizações é lenta, i.e., não imediata Eventualmente, cada atualização atingirá cada nó

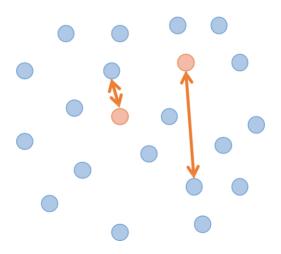
### Duas formas de epidemia

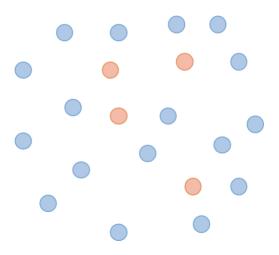
Anti-entropy: Cada nó regularmente escolhe outro nó aleatoriamente e intercambia seu estado, levando a estados idênticos Rumor: Um nó que foi atualizado (i.e., foi contaminado), avisa a outros nó sobre a atualização (contaminando outros).

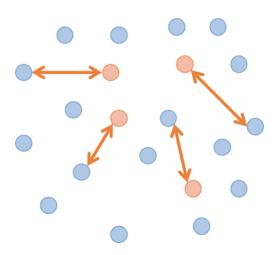
```
O que é gossiping?
Node n
                              Nó, Thread ou Processo
  n.run():
                              Método main executado por Node n
     while true:
       sleepMs(x)
                              Cada certo tempo acorda e faz algo (gossip)
       executeGossip()
  n.executeGossip():
    p = selectNode()
    infoLocal = getLocalInfo()
    p.shareInfo(infoLocal, n)
                                        Via RPC ao Nó p
  n.shareInfo(info, q):
                                        Orientado a evento (muitos Nós
    addInfo(info)
                                        podem chamá-lo ao mesmo tempo)
    infoLocal = getLocalInfo()
    q.updateInfo(infoLocal)
                                        Via RPC ao Nó q
  n.updateInfo(info):
                                        Orientado a evento (muitos Nós
    addInfo(info)
                                        podem chamá-lo ao mesmo tempo)
```

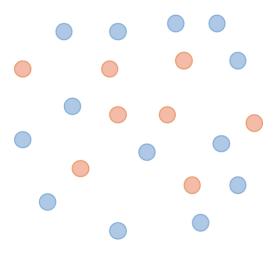


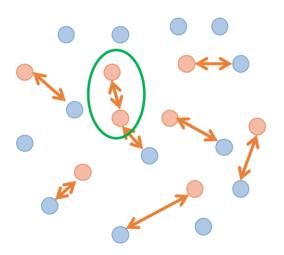


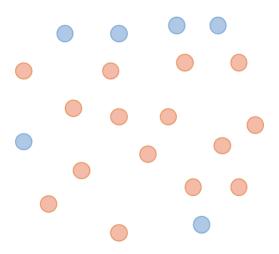


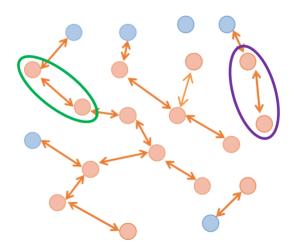


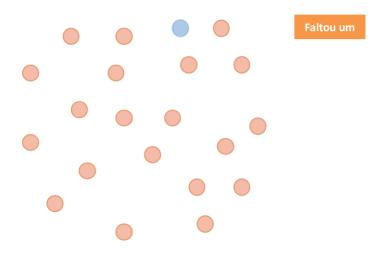












# Gossip: Protocolos Epidêmicos → Anti-entropy

### Princípios

Um nó P seleciona outro nó Q do sistema aleatoriamente.

Pull (puxar): P somente pede novas atualizações de Q.

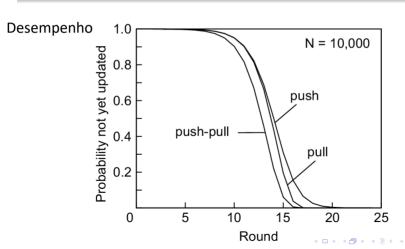
Push (empurrar): P somente envia novas atualizações a Q, sem Q ter pedido.

Push-pull: P e Q enviam atualizações um a outro.

# Gossip: Protocolos Epidêmicos → Anti-entropy

#### Observação

push-pull usa O(log(N)) rodadas para disseminar as atualizações nos N nós (rodada = quando cada nó tomou a iniciativa de iniciar o intercâmbio).



### Gossip: Protocolos Epidêmicos → Rumor (boato)

#### Modelo básico

Um nó S, com uma atualização a disseminar, contata outros nós. Se o nó contatado já possui a atualização, S para de contatar outros nós com probabilidade  $p_{stop}$ .

#### Observação

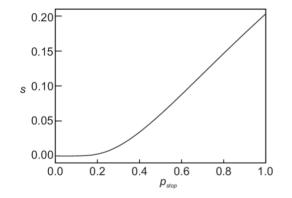
Se s é a fração de nós ignorantes (i.e., não tem a atualização), pode ser demonstrado (via SIR) que, para muitos servidores:

$$s = e^{-(1/p_{stop}+1)(1-s)}$$

# Gossip: Protocolos Epidêmicos → Rumor (boato)

### O efeito de parar

$$s = e^{-(1/p_{stop}+1)(1-s)}$$

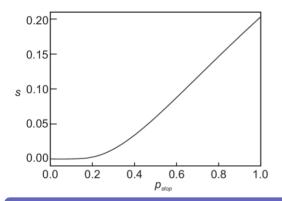


Considere 10,000 nós		
1/p <sub>stop</sub>	s	Ns
1	0.203188	2032
2	0.059520	595
3	0.019827	198
4	0.006977	70
5	0.002516	25
6	0.000918	9
7	0.000336	3

# Gossip: Protocolos Epidêmicos → Rumor (boato)

### O efeito de parar

$$s = e^{-(1/p_{stop}+1)(1-s)}$$



Considere 10,000 nós		
1/p <sub>stop</sub>	S	Ns
1	0.203188	2032
2	0.059520	595
3	0.019827	198
4	0.006977	70
5	0.002516	25
6	0.000918	9
7	0.000336	3

### Nota

Se realmente quer estar seguro de atualizar TODOS os nós, o rumor por si só não é suficiente

# Gossip: Remoção de dados

#### Problema Fundamental

Não é possível remover um valor antigo de um nó e esperar que isso se dissemine. Pelo contrário, a remoção será desfeita pelo uso do algoritmo epidêmico

### Solução

A remoção deve ser registrada como uma atualização "especial" usando um death certificate

### Conceitos adquiridos

- Comunicação transiente/persistente, assíncrona/síncrona.
- Comunicação RPC.
- Comunicação MOM (Event Streaming).
- Kafka.
- Multicast com ordem FIFO, Causal e Total.
- Comunicação Gossip: anti-entropy e rumor.

### Agenda

- Fundamentos
- Comunicação orientada a procedimento (RPC)
- Comunicação orientada a mensagem (MOM)
- Comunicação multicast (Gossip / Flooding
- Comunicação orientada a fluxo

# Comunicação orientada a fluxo (streams)

- Suporte para mídia contínua
- Fluxo em sistemas distribuídos
- Qualidade de Serviço (QoS)

# Suporte para mídia contínua

### Observação

Toda a comunicação apresentada foi baseada em um intercâmbio de informação discreto e independente do tempo

### Mídia Contínua

Caracterizada por ter valores dependentes do tempo:

Áudio

Vídeo

Animações

Sensores (temperatura, pressão, etc.)

# Suporte para mídia contínua

#### Modos de Transmissão

Diferentes garantias de tempo na entrega de dados:

Asynchronous: sem restrições de quando a **o pacote** deve ser entregue

Synchronous: define um delay (end-to-end) máximo para a entrega do pacote

Isochronous: define um delay (end-to-end) máximo e mínimo para a entrega do pacote (*jitter*)

### Fluxo em sistemas distribuídos

### Definição

Um fluxo (contínuo) de dados é uma comunicação orientada à conexão que suporta transmissão de dados isochronous.

#### Características

Fluxos são unidirecionais Geralmente há uma única fonte

Fluxo simple: único fluxo de dados, e.g., áudio ou vídeo Fluxo complexo: múltiplos fluxos de dados, e.g., áudio estéreo ou combinação de áudio/vídeo

#### Ideia

Como especificar a Qualidade de Serviço (QoS)?

Exemplos:

Bit rate requerido no transporte.

Delay máximo até criar a sessão (i.e., quando a aplicação pode começar a enviar dados).

Delay máximo do jitter

### Observação

Os pacotes podem ser priorizados por ferramentas inseridas na camada de rede

### **Também**

Uso de buffers na camada de aplicação para reduzir o jitter:

Packet departs source 1 2 3 4 5 6 7 8

Packet arrives at buffer 1 2 3 4 5 6 7 8

Packet removed from buffer Time in buffer 1 2 3 4 5 6 7 8

Gap in playback Gap in playback Time (sec)

#### **Problema**

Como reduzir o efeito de pacotes perdidos usando UDP (quando múltiplos quadros estão em um mesmo pacote)?

Exemplo, 4 quadros de áudio em cada pacotes.

